

프로그래밍 언어별 개발자 연봉 분석과 고연봉 예측

Stack Overflow Developer Survey의 공통 정제 데이터를 기반으로 다섯 개 언어 도메인의 EDA·통계 검증·시각화를 수행하고, 전체 응답자의 언어 및 개발자 특성으로 연봉 중앙값 이상 여부를 예측했습니다.

설문 기준 연도 2025 공식 Archive 데이터	최종 정제 응답 21,678	통계 비교 언어 14개 제외: Julia(0명)	ML 목표 중앙값 이상 학습 기준 \$76,340.5	Full model F1 81.0%	Full ROC-AUC 89.0%
D1 이승미 DYNAMIC / DATA	D2 조윤호 JVM / ENTERPRISE	D3 박수빈 WEB	D4 문관영 SYSTEM	D5 신동민 PLATFORM / BACKEND	D6 백지현 INTEGRATED ML

METHOD & DATA QUALITY

공통 데이터와 전처리

각 도메인은 별도 CSV를 만들지 않고 중앙에서 정제한 `code/data/results.csv` 를 직접 읽습니다. 이 방식으로 전처리 기준은 통일하면서 분석은 독립적으로 재실행할 수 있습니다.

01 · LOAD 49,191행 연봉·언어·경력·직무 등 원본 설문 로딩	02 · CLEAN 22,121행 필수값·양수 연봉·ResponseId 중복 처리	03 · FILTER 21,678행 연봉 하위 1%·상위 1% 이상치 제거	04 · FEATURE 14개 언어 세미콜론 토큰 기반 언어별 0/1 플래그
--	---	---	--

동일 처리 원칙

- 연봉·언어 결측 및 0 이하 연봉 제거
- ResponseId 중복 제거
- 전문 경력 숫자 변환
- 전 세계 동일 국가 범위 사용
- 언어 최소 표본 100명 적용

해석상 주의

- 복수 언어 사용자는 여러 언어 그룹에 중복 포함
- Java와 JavaScript는 정확한 토큰 분리로 구분
- 공통 CSV의 중앙 연봉은 \$75,744
- ML 임계값은 누수를 막기 위해 학습 데이터에서만 계산

Pandas·Polars 로딩 및 결과 비교

라이브러리	행	열	로딩 시간	평균 연봉	중앙 연봉	컬럼 일치	요약값 일치
Pandas	21,678	27	0.0285초	\$89,448	\$75,744	True	True
Polars	21,678	27	0.0189초	\$89,448	\$75,744	True	True

비교 결론

Pandas와 Polars는 21,678행과 27개 컬럼, 평균·중앙 연봉에서 동일한 결과를 냈습니다. 2026-08-05 재실행의 로딩 시간은 Pandas 0.0285초, Polars 0.0189초입니다.

동적·데이터 언어

담당 · 이송미

데이터·AI 분야에서 주로 사용하는 언어별 연봉·경력·직무 차이를 분석합니다.

Python · R · Julia

최소 표본 기준 적용

2025 원본에서 Julia 응답은 0명이므로 최소 표본 100명 기준에 따라 기술통계와 검정에서는 제외했습니다.

최다 사용자

Python

12,457명

최고 중앙 연봉

Python

\$76,570


비교 언어

2개

최소 표본 기준 적용

기술통계

언어	사용자	평균	중앙값	표준편차	Q1	Q3	평균 경력
Python	12,457	\$92,075	\$76,570	\$72,043	\$40,605	\$126,000	13.1년
R	984	\$86,430	\$71,328	\$69,283	\$35,965	\$120,000	13.8년



통계 검정

- 검정: 양측 Welch 독립표본 t-test
- Python 전용군: n=11,607
- R 전용군: n=134
- t-statistic: 0.7428
- p-value: 0.458893
- 해석: 5% 유의수준에서 Python 전용군과 R 전용군의 평균 연봉 차이는 통계적으로 유의하지 않다.

핵심 해석

- 평균과 중앙값을 함께 보면 언어별 연봉 수준과 분포의 비대칭성을 구분할 수 있다.
- 표본 수가 크게 다른 언어 비교에는 평균만이 아니라 중앙값과 사분위 범위를 함께 사용해야 한다.
- t-test는 두 언어를 동시에 사용하는 응답자를 제외해 독립 표본에 가깝게 구성했다.

분석 한계

- 복수 언어 사용자와 국가·직무·경력 차이가 관찰된 연봉 차이에 함께 반영될 수 있다.
- 설문 관찰 자료이므로 특정 언어 사용이 높은 연봉의 원인이라고 해석할 수 없다.

자동 생성 파일: [summary.csv](#) · [salary_boxplot.png](#) · [result.md](#)

JVM·엔터프라이즈 언어

담당 · 조윤호

JVM 기반 언어 사용자의 연봉·경력·직무·조직 규모 차이를 분석합니다.

Java · Kotlin · Scala

최다 사용자

Java

6,134명

최고 중앙 연봉

Scala

\$95,674

비교 언어


3개

최소 표본 기준 적용

기술통계

언어	사용자	평균	중앙값	표준편차	Q1	Q3	평균 경력
Java	6,134	\$89,331	\$75,000	\$71,832	\$37,999	\$121,000	13.4년
Kotlin	2,355	\$91,382	\$80,000	\$70,084	\$42,286	\$121,815	12.7년
Scala	570	\$112,505	\$95,674	\$81,577	\$52,232	\$155,000	14.2년

2025 Stack Overflow JVM Developer Analysis



Pandas·Polars 검증

두 라이브러리가 동일한 행·열·연봉 평균·중앙값을 반환하는지 비교했으며, 결과는 공통 전처리 절에 함께 제시했습니다.

통계 검증

- 검정: 양측 Welch 독립표본 t-test
- Java 전용군: n=4,539
- Kotlin 전용군: n=760
- t-statistic: -0.3164
- p-value: 0.751722
- 해석: 5% 유의수준에서 Java 전용군과 Kotlin 전용군의 평균 연봉 차이는 통계적으로 유의하지 않다.

핵심 해석

- JVM 언어별 연봉은 평균·중앙값·사분위 범위를 함께 비교해야 한다.
- 연봉과 전문 경력의 Pearson 상관계수는 차트와 표에서 동시에 확인할 수 있다.
- Pandas와 Polars는 동일한 데이터 크기와 핵심 연봉 요약값을 산출했다.

분석 한계

- 복수 언어 사용자는 언어별 기술통계에 중복 포함될 수 있다.
- 국가·직무·경력 등 교란 요인을 통제하지 않은 관찰 분석이므로 인과관계로 해석할 수 없다.

자동 생성 파일: [summary.csv](#) · [salary_chart.png](#) · [pandas_polars_comparison.csv](#) · [result.md](#)

웹 개발 언어

담당 · 박수빈

웹 언어별 연봉 수준, 경력별 변화와 프론트엔드·백엔드·풀스택 직무 구성을 분석합니다.

JavaScript · TypeScript · PHP

최다 사용자

JavaScript

14,606명

최고 중앙 연봉

TypeScript

\$79,315


비교 언어

3개

최소 표본 기준 적용

기술통계

언어	사용자	평균	중앙값	표준편차	Q1	Q3	평균 경력
JavaScript	14,606	\$88,058	\$75,410	\$67,436	\$40,000	\$120,000	13.5년
TypeScript	10,151	\$91,521	\$79,315	\$68,420	\$43,664	\$125,000	12.5년
PHP	4,010	\$71,217	\$60,155	\$58,029	\$28,424	\$98,612	14.3년

자동 생성 파일: [summary.csv](#) · [salary_comparison.png](#) · [salary_interactive.html](#) · [result.md](#)

Plotly 인터랙티브 시각화

경력 구간별 중앙 연봉, 직무 구성, 연봉 분포를 탐색하는 독립형 [code/domain3_web/salary_interactive.html](#)도 분석 실행 시 자동 생성됩니다.

통계 검정

- 검정: JavaScript 전용군과 TypeScript 전용군의 양측 Welch t-test
- JavaScript 전용군: n=5,633, 평균 \$83,888
- TypeScript 전용군: n=1,178, 평균 \$97,951
- t-statistic: -6.2760
- p-value: 4.43931e-10
- 해석: 5% 유의수준에서 평균 연봉 차이는 통계적으로 유의하다.

핵심 해석

- 웹 언어별 연봉은 평균·중앙값·사분위 범위를 함께 비교해야 한다.
- 경력 구간별 중앙 연봉 차트로 경력 구성 차이가 언어별 연봉 차이에 미치는 영향을 확인할 수 있다.
- 직무 비율과 복수 언어 사용을 함께 고려해야 단순한 언어 효과로 과대해석하지 않을 수 있다.

분석 한계

- Stack Overflow 질문은 온라인 커뮤니티 기반 표본이므로 모집단 대표성에 한계가 있다.
- 대부분의 개발자가 여러 언어를 함께 사용하므로 한 언어의 순수한 인과 효과를 분리하기 어렵다.

시스템 프로그래밍 언어

담당 · 문관영

시스템 언어 사용자의 연봉·경력·직무 특성을 비교합니다.

C · C++ · Rust

최다 사용자

C++

4,480명

최고 중앙 연봉

Rust

\$82,000


비교 언어

3개

최소 표본 기준 적용

기술통계

언어	사용자	평균	중앙값	표준편차	Q1	Q3	평균 경력
C	3,972	\$87,061	\$72,496	\$72,173	\$34,804	\$120,000	14.0년
C++	4,480	\$88,745	\$73,516	\$72,938	\$37,094	\$120,000	13.7년
Rust	3,031	\$99,774	\$82,000	\$76,318	\$46,406	\$136,141	11.9년



통계 검정

- 검정: 양측 Welch 독립표본 t-test
- C++ 전용군: n=3,367, 평균=\$85,769
- Rust 전용군: n=1,918, 평균=\$100,951
- t-statistic: -7.3050
- p-value: 0.000000
- 해석: 5% 유의수준에서 C++ 전용군과 Rust 전용군의 평균 연봉 차이는 통계적으로 유의하다.

핵심 해석

- 시스템 언어별 연봉은 중앙값과 사분위 범위까지 함께 비교해야 한다.
- Rust와 C++ 비교에서는 두 언어를 동시에 사용하는 응답자를 제외했다.
- 직무·경력 구성 차이를 함께 확인해야 언어별 연봉 차이를 과대해석하지 않을 수 있다.

분석 한계

- 언어별 그룹은 기술통계에서 서로 중복될 수 있다.
- 관찰 자료이므로 언어 사용과 연봉 사이의 인과관계를 의미하지 않는다.

자동 생성 파일: [summary.csv](#) · [salary_boxplot.png](#) · [result.md](#)

플랫폼.백엔드 언어

담당 · 신동민

플랫폼 및 백엔드 언어 사용자의 연봉·조직 규모·근무 형태·경력 분포를 분석합니다.

C# · Go · Swift

최다 사용자

C#

6,309명

최고 중앙 연봉

Swift

\$90,723

비교 언어

3개

최소 표본 기준 적용

기술통계

언어	사용자	평균	중앙값	표준편차	Q1	Q3	평균 경력
C#	6,309	\$89,260	\$78,633	\$63,073	\$45,509	\$120,471	14.8년
Go	3,679	\$104,710	\$88,494	\$78,364	\$48,000	\$145,917	13.0년
Swift	1,156	\$102,127	\$90,723	\$73,749	\$50,000	\$140,000	14.5년

근무 특성

Remote, Hybrid / flexible, In-person 비율과 조직 규모 구성을 함께 비교해 단순 연봉 차이의 과대해석을 줄였습니다.

통계 검증

독립 표본 가정을 위해 C#과 Go를 동시에 사용한 응답자는 검증에서 제외했다. 등분산을 가정하지 않는 양측 Welch t-test를 적용했다.

- C# 전용군: n=5,453, 평균 \$87,776
- Go 전용군: n=2,823, 평균 \$106,529
- 평균 차이(C# - Go): \$-18,753
- 95% 신뢰구간: [\$-22,129, \$-15,376]
- t(4581.5) = -10.887, p = 2.855e-27
- 결론: 5% 유의수준에서 두 그룹의 평균 연봉 차이는 통계적으로 유의하다.

핵심 해석


- 세 언어의 연봉은 평균뿐 아니라 중앙값·표준편차·사분위 범위를 함께 봐야 한다.
- 언어별 원격근무 비율과 조직 규모 구성에 차이가 있어 연봉 결과와 함께 해석해야 한다.
- C#과 Go를 동시에 쓰는 응답자를 검증에서 제외해 독립표본 조건을 보완했다.

분석 한계

- 이 분석은 관찰 데이터의 기술통계이며, 언어 사용이 연봉 차이의 원인임을 의미하지 않는다.
- 국가, 직무, 경력, 조직 규모 등의 교란 요인을 별도로 통제하지 않았다.

자동 생성 파일: [summary.csv](#) · [salary_chart.png](#) · [result.md](#)

Platform Languages: Salary and Organization Size



통합 고연봉 예측

담당 · 백지현

Domain 1~5 집계 파일이 아닌 공통 응답자 단위 CSV에서 전체 주요 언어와 개발자 특성을 직접 학습합니다.

정확한 목표 변수

HighSalary 는 실제 연봉 금액을 예측하는 회귀값이 아니라, 학습 데이터의 연봉 중앙값 \$76,340.5 이상인지 분류하는 이진 목표입니다.

전체 유효 표본

21,678

학습 / 테스트

17,342 / 4,336

학습 클래스 0 / 1

8,671 / 8,671

모델 재로드 검증

성공

ColumnTransformer + Pipeline

01 · INPUT

공통 CSV

응답자 단위 데이터

02 · PREPROCESS

결측 대처·스케일링

범주형 One-Hot Encoding

03 · MODEL

LogisticRegression

class_weight=balanced

04 · OUTPUT

평가·joblib 저장

Pipeline 전체 재로드 확인

입력 특성

수치형 YearsCodeProNumeric, LanguageCount

범주형 RemoteWork, DevType, EdLevel, Employment, OrgSize, Country

언어 14개 유효 언어 플러그와 원본 스키마 호환용 Julia 0값 컬럼을 포함한 총 15개 컬럼

누수 방지

ResponseId, ConvertedCompYearly, LogSalary, 원본 언어 문자열과 HighSalary는 입력에서 제외했습니다. 중앙값은 train/test 분리 후 학습 데이터로만 계산했습니다.

Domain 1~5의 집계값과 검증 결과는 모델 특성이 아니라 최종 해석에만 사용합니다.

모델 비교

다수 클래스 기준선

Dummy

Accuracy	50.8%
Precision	0.0%
Recall	0.0%
F1	0.0%
ROC-AUC	50.0%

언어와 언어 개수

Language-only

Accuracy	56.3%
Precision	55.0%
Recall	62.4%
F1	58.4%
ROC-AUC	59.5%

경력·직무 등 프로필

Profile-only

Accuracy	80.4%
Precision	79.6%
Recall	80.8%
F1	80.2%
ROC-AUC	88.5%

언어와 프로필 통합

Full model


Accuracy	81.0%
Precision	80.0%
Recall	82.1%
F1	81.0%
ROC-AUC	89.0%

언어 정보의 추가 기여

Profile-only 대비 Full model의 F1 증가는 +0.008, ROC-AUC 증가는 +0.005입니다. 프로필이 대부분의 예측력을 설명하지만 언어 정보도 소폭의 추가 신호를 제공합니다.

통합 고연봉 예측 · 평가 결과

혼동행렬



핵심 계수 해석

다른 입력을 함께 고려했을 때 국가 특성 중 Switzerland(+4.152)와 United States(+3.415)가 가장 큰 양의 계수였습니다. 언어 계수는 Scala(+0.556), TypeScript(+0.399), Go(+0.373)가 양의 방향, PHP(-0.543)가 가장 큰 음의 방향이었습니다.

관측 연봉 요약

언어별 관측 중앙 연봉 상위는 Scala(\$95,674), Swift(\$90,723), Go(\$88,494) 순입니다. 다만 계수는 연봉 증가액이 아니며 국가·경력·직무를 함께 반영한 분류 방향으로만 해석해야 합니다.

모델 해석 범위

로지스틱 회귀 계수는 연봉 증가액이 아니라 다른 입력을 함께 고려했을 때 중앙값 이상 분류와 연결되는 방향입니다. 인과 효과나 개인 연봉을 보장하지 않으며 채용·보상 의사결정에 사용해서는 안 됩니다.

ASSIGNMENT RUBRIC

과제 평가 항목 대응

안내서 3-4쪽 기준

평가 항목을 실제 코드와 산출물에 연결해 채점 근거를 바로 확인할 수 있도록 정리했습니다.

평가 영역	구현 내용	근거 산출물	상태
데이터 준비:EDA	Pandas-Polars 로딩 비교, 결측·중복·이상치 처리, 공통 EDA	로딩 비교 CSV · 전처리 메타데이터	충족
시각화	Seaborn 정적 차트와 Plotly 인터랙티브 차트, 제목·축 레이블 포함	Seaborn · Plotly	충족
통계 분석	평균·표준편차·분위수, Pearson 상관계수, scipy.stats.ttest_ind와 p-value 해석	통합 report.md · Domain 1-5 결과	충족
ML Pipeline	ColumnTransformer 전처리와 LogisticRegression을 Pipeline으로 결합하고 성능 평가	평가 지표 · 저장 모델	충족
자동화	Domain 1-6 실행 후 report.md와 실행 로그 자동 생성	run_all.py · report.md	충족
완성도	함수 설명·핵심 로직 주석, 데이터 누수·언어 토큰 분리·산출물 검증 테스트	실행 로그 · 자동 테스트 18개	충족

데이터 연도 고지

과제 안내서 2쪽에는 Stack Overflow Survey 2024 링크가 제시되어 있으나, 본 팀은 동일 공식 Archive의 2025 설문을 선택해 전 도메인을 일관되게 분석했습니다. 결과표·모델·차트의 연도는 모두 2025로 통일되어 있습니다.

평가 범위 고지

과제 안내서에는 5분 팀 발표가 포함되어 있으나 본 제출물 범위에서는 발표 자료를 제외했습니다. 발표가 별도 면제되지 않았다면 해당 항목은 문서만으로 충족할 수 없습니다.

EXECUTION & SUBMISSION

실행 검증과 제출 근거

2026-08-05 재검증

Domain 1-6

6/6 성공

모든 종료 코드 0

통합 Markdown

생성 성공

code/report.md

자동 테스트

18 passed

실패 0건

저장 모델 재로드

검증 성공

예측 결과 동일

실행 결과

2026-08-05 13:00 KST에 `./venv/bin/python scripts/run_all.py` 를 실행해 Domain 1-6, 통합 `report.md` , 자동 테스트까지 연속 검증했습니다. 전체 출력은 execution_log.txt에 보존했습니다.

```
$ ./venv/bin/python scripts/run_all.py
[Domain 1] exit_code: 0    [Domain 2] exit_code: 0
[Domain 3] exit_code: 0    [Domain 4] exit_code: 0
[Domain 5] exit_code: 0    [Domain 6] exit_code: 0
[통합 report.md] exit_code: 0
[자동 테스트] 18 passed in 1.05s
```

분석 결과에 대한 의견

언어별 연봉 차이는 실제로 관찰되지만 언어 정보만 사용한 모델의 F1은 0.584에 그쳤습니다. 반면 경력·직무·학력·근무 형태·조직 규모·국가를 포함한 전체 모델은 F1 0.810을 기록했습니다. 따라서 특정 언어 자체가 고연봉을 만든다고 보기보다 개발자의 경력과 직무 환경을 함께 해석해야 합니다.

코드 품질 및 개선 의견

공통 설정과 정제 데이터를 중앙화하고, 정확한 언어 토큰 분리, 독립표본 구성, 학습 데이터 기준 타깃 생성, Pipeline 재로드 검증을 적용했습니다. 후속 작업에서는 교차검증, 국가별 구매력 보정, 효과크기·신뢰구간 확대와 다음 설문 연도 외부 검증이 필요합니다.

제출 파일 구성

과제 안내서 5쪽의 PDF 제출 요구에 맞춰 이 정적 HTML과 동일 내용을 담은 code/output/pdf/integrated_report.pdf를 함께 제공합니다. 인터랙티브 Plotly 결과와 재실행 가능한 코드는 `code/` 폴더에 있으므로 전체 폴더를 ZIP으로 제출해야 합니다.

CONCLUSION

종합 결론과 개선 방향

01 · 언어별 차이

각 언어 계열에서 연봉 중앙값과 분포 차이가 관찰됐지만, 경력·직무·국가·조직 규모가 함께 반영된 결과입니다.

02 · 통계 검증

비교 언어 동시 사용자를 제외한 Welch t-test로 독립표본 조건을 보완하고 p-value를 5% 유의수준에서 해석했습니다.

03 · 통합 예측

Full model의 F1은 0.810, ROC-AUC는 0.890이며 프로필에 언어 정보를 더했을 때 성능이 소폭 향상됐습니다.

한계

- Stack Overflow 설문은 무작위 모집단 표본이 아닙니다.
- 연봉은 자기보고 값이며 국가별 임금·생활비 차이가 큼니다.
- 복수 언어 사용으로 기술통계 그룹이 서로 독립적이지 않습니다.
- 단일 train/test split 결과이므로 일반화에 주의해야 합니다.

후속 개선

- 국가별 생활비 및 구매력 보정
- 교차검증과 하이퍼파라미터 탐색
- 언어 비교의 효과크기·신뢰구간 확대
- 다음 설문 연도 외부 검증

재현성

code/scripts/run_all.py 는 공통 code/data/results.csv 를 기반으로 Domain 1~6 산출물, code/report.md , 실행 로그를 다시 생성합니다. 본 HTML과 제출용 PDF는 정적 최종 문서로 별도 관리되며 실행 스크립트가 덮어쓰지 않습니다.